Adaptive RAG para Contratações Públicas do RJ

Consultas com cálculos e evidências em quatro bases de conhecimento

Grande Desafio de IA Generativa & RAG

Residência TIC em Trilhas · PUC-Rio · Instituto ECOA

Demo Day · 23 de outubro de 2026

1. Problema e motivação

Informações espalhadas em formatos diferentes

Equipes de compras, pesquisadores e profissionais de controle

Uma consulta pode exigir uma contagem, um trecho de ata ou uma regra da lei.

Objetivo
Reduzir a busca manual e permitir a conferência do resultado nas fontes.

2. Dados utilizados

Base	Conteúdo utilizado	Chunks
Estruturada	1.358 registros de contratações do PNCP	1.358
Agregada	PCA e itens do PE 038/26/2026	519
Conversacional	3 atas em PDF e 1 comunicação sintética	78
Normativa	Lei nº 14.133/2021 em HTML	217

8 arquivos brutos **2.172 chunks indexados**

Recorte dos dados e limites de cobertura

PNCP

Publicação: 01/03/2026 a 31/03/2026, associada ao RJ.
O ano da compra pode ser diferente do ano da publicação.

ARQUIVOS AGREGADOS

PCA 2026: 36.994 linhas. PE 038/26/2026: 19 itens.
Os cálculos usam todas as linhas dos arquivos carregados.

Formatos: JSON, CSV, PDF, HTML e TXT. O corpus não cobre todo o PNCP.
A origem do arquivo define o recorte do PCA, sujeito à conferência.

3. Arquitetura: preparação do corpus

Etapa	Função
Inventário e hashes	Identificar arquivos, versões e integridade
Extração e chunks	Separar trechos e preservar metadados
Indexação	Gerar embeddings e índices FAISS e BM25
Restauração	Carregar o pacote validado sem gerar embeddings novamente

A entrega usa o pacote congelado de 2.172 chunks.
A automação de coleta cobre parte do processo e ainda exige evolução.

A estratégia depende da pergunta

Pergunta na interface

Planejamento: intenção, bases, filtros e operação

Cálculo ou listagem

Executor consulta registros
ou arquivos completos.

Consulta documental

FAISS + BM25 + RRF
Seleciona evidências e gera
a resposta com citações.

Consulta combinada: resultado calculado e resposta documental separados

4. Apresentação do sistema

PERGUNTAR E CONFERIR

O usuário consulta, lê a resposta e inspeciona
os filtros, as fontes e as evidências.

HISTÓRICO E FEEDBACK

Consultas e avaliações ficam persistidas nesta instância.
Logs associam as etapas ao mesmo run_id.

Sem evidência: limitação explícita. Dados pessoais: proteção e recusa.
O histórico é compartilhado entre pessoas com acesso à instância.

5. Demonstração prática: cálculo

No PE 038/26/2026, quantos itens foram homologados, fracassados e desertos e qual foi a soma dos valores homologados?

19 itens

8 homologados
9 fracassados
2 desertos

R$ 141.002,08

Soma dos valores homologados informados.
Fonte: CSV da contratação selecionada.

Demonstração 2: ata e registro do PNCP

Informe o objeto da ata nº 191/2026 da EBSERH e o número PNCP da contratação correspondente.

OBJETO

Aquisição de peças mamógrafas (chassis) para o complexo hospitalar da UFRJ.

NÚMERO DE CONTROLE PNCP

15126437000305-1-000676/2026

Consulta normativa e limitação

O que a Lei nº 14.133/2021 estabelece sobre o pregão?

RESPOSTA A CONFERIR

Definição, aplicação e exceções,
com referências ao art. 6º e ao art. 29.

Limitação documentada
Pedidos de médias monetárias ainda exigem esclarecimento.
O executor não substitui o cálculo por trechos de documentos.

Resultados e alcance da validação

585

testes locais aprovados

2

testes de compatibilidade dos artefatos aprovados

7

testes de integração real aprovados

Reprodução em clone local e ambiente virtual isolado no mesmo Colab.

Avaliação complementar de Janice: 9/9 personas no protocolo recebido, com ressalvas de rastreabilidade e sem identificação do commit base.

Valor prático e próximos passos

Uma pergunta pode exigir estratégias diferentes

A versão reúne cálculos sobre arquivos completos
e respostas documentais com fontes verificáveis.

Limites atuais

Coleta automatizada parcial e metadados de vigência a revisar.
Centralização da configuração e testes de metadados a reforçar.
Serviço de LLM pode atrasar. Reprodução externa ainda pendente.